

RAPPORT D'ETUDE INTERMEDIAIRE

Maintenance Predictive par Machine Learning

Dataset NASA CMAPSS — Turbofan Engine Degradation

Auteurs	Stéphanie CALLEGARI
Date	03 Mai 2026
Statut	Rapport intermédiaire — Semaine 1 / 3

SOMMAIRE

1. Contexte et Objectifs

2. Description du Dataset

3. Exploration et Visualisation

3.1 Evolution des capteurs — signaux de dégradation

3.2 Distribution de la durée de vie

3.3 Evolution de la RUL sur la flotte

4. Pipeline Machine Learning

4.1 Feature Engineering

4.2 Choix du modèle — Random Forest Regressor

5. Résultats

6. Prochaines Etapes

CONCLUSION

1. Contexte et Objectifs

La maintenance prédictive est un enjeu opérationnel majeur pour l'industrie aéronautique et énergétique. Anticiper la défaillance d'un équipement permet de réduire les arrêts non planifiés, d'optimiser les interventions de maintenance et de garantir la sécurité des opérations.

Ce projet construit un pipeline complet de prédiction de la **Remaining Useful Life (RUL)** — durée de vie résiduelle — de moteurs de turboréacteurs à partir de données capteurs. Le dataset utilisé est le **NASA CMAPSS (Commercial Modular Aero-Propulsion System Simulation)**, référence académique internationale en santé des équipements industriels (PHM).

Objectif opérationnel : fournir un outil fiable, rapide et interprétable permettant aux équipes de maintenance d'identifier les moteurs nécessitant une intervention avant panne — sans attendre les signaux tardifs de dégradation. Le livrable final sera un dashboard interactif Streamlit simulant une vue flotte en temps réel.

2. Description du Dataset

Le sous-ensemble FD001 contient des séries temporelles de dégradation de moteurs opérant dans des conditions uniformes. Chaque moteur démarre en bon état et se dégrade progressivement jusqu'à la panne — sans maintenance intermédiaire.

Caractéristique	Valeur	Description
Lignes totales	20 631	Cycles de fonctionnement enregistrés
Colonnes brutes	26	2 identifiants + 3 conditions op. + 21 capteurs
Moteurs	100	Moteurs distincts dans le jeu d'entraînement
Durée de vie moyenne	206 cycles	Cycles avant panne (moyenne)
Durée de vie min / max	128 / 362 cycles	Variabilité naturelle de la flotte
Capteurs informatifs	14 / 21	Capteurs présentant une dérive significative

La variable cible RUL a été construite par : **RUL = cycle_max - cycle_actuel**. Cette formule suppose une dégradation linéaire — hypothèse de base validée pour FD001, qui sera affinée dans les prochaines versions.

3. Exploration et Visualisation

3.1 Evolution des capteurs — signaux de dégradation

L'analyse des séries temporelles par capteur révèle deux comportements distincts : s2, s3, s4 montrent une dérive croissante avec la dégradation (le moteur chauffe et subit des pressions accrues), tandis que s7 montre une tendance inverse. Les deux types de dérive sont des signaux utiles pour le modèle.




Figure 1 — Evolution du capteur s2 (température) pour le moteur 1. La tendance croissante s'accroît à l'approche de la panne.




Figure 2 — Comparaison de 4 capteurs. s7 dérive à la baisse contrairement aux trois autres — deux types de signaux complémentaires.

3.2 Distribution de la durée de vie

La distribution des durées de vie révèle une forte concentration entre 150 et 250 cycles avec un pic autour de 200 cycles. La queue droite (quelques moteurs atteignant 350+ cycles) indique une variabilité que le modèle devra gérer.




Figure 3 — Distribution des durées de vie initiales. Distribution asymétrique à droite, pic à 200 cycles.

3.3 Evolution de la RUL sur la flotte




Figure 4 — RUL en fonction du cycle pour 20 moteurs. Chaque droite décroissante représente un moteur — la variabilité des durées de vie est clairement visible.

4. Pipeline Machine Learning

4.1 Feature Engineering

Deux transformations ont été appliquées aux 14 capteurs informatifs identifiés lors de l'exploration :

Transformation	Description	Justification technique
Moyenne glissante (window=5)	Moyenne des 5 derniers cycles par capte	Supprime le bruit de mesure haute fréquence et révèle tendance de dégradation
Normalisation MinMax [0,1]	Ramene toutes les valeurs entre 0 et 1	Mise à l'échelle nécessaire : s2 ~ 642, s15 ~ Sans normalisation le modèle serait biaisé

Après transformation : **20 631 observations x 14 features**, toutes normalisées entre 0 et 1.

4.2 Choix du modèle — Random Forest Regressor

Le Random Forest a été retenu comme modèle de référence pour cette première version : il est robuste au bruit, résistant au sur apprentissage, et interprétable via l'importance des features. C'est le bon choix pour une première version industrielle — fiable et rapide à mettre en production. Le Gradient Boosting (XGBoost) sera évalué dans la version suivante pour viser un RMSE inférieur à 25 cycles.

Configuration : 100 arbres de décision, séparation 80/20 train/test, random_state=42 pour la reproductibilité des résultats.

5. Résultats

Métrique	Valeur	Interprétation
RMSE	33,6 cycles	Erreur quadratique — pénalise les grandes erreurs
MAE	22,9 cycles	Ecart moyen entre prédiction et réalité
Train / Test	16 504 / 4 127 obs.	Split 80/20 — bonne généralisation




Figure 5 — Prédications vs Réalité (Random Forest). La diagonale rouge représente la prédiction parfaite. Le modèle est particulièrement précis pour les faibles RUL (zone critique 0-100 cycles).

Le graphique révèle un comportement conservateur du modèle pour les RUL élevées (200+ cycles) : il sous-estime la durée de vie restante. En contexte industriel, ce biais est acceptable — il vaut mieux déclencher une inspection préventive trop tôt que trop tard.

6. Prochaines Etapes

Etape	Objectif	Statut
Exploration & Visualisation	Comprendre les données et les signaux de dégradation	Terminé
Feature Engineering	Préparer les données pour le ML	Terminé
Random Forest	Modèle de référence — MAE 22,9 cycles	Terminé
Gradient Boosting	Amélioration du modèle — cible MAE < 20 cycles	En cours
Importance des features	Identifier les capteurs les plus prédictifs	A venir
Dashboard Streamlit	Interface vue moteur et vue flotte	A venir
Déploiement & Documentation	Streamlit Cloud + README GitHub	A venir

Conclusion

En 4 jours de développement, un pipeline industriel complet a été mis en place : chargement et exploration du dataset NASA CMAPSS, feature engineering avec lissage et normalisation, entraînement d'un Random Forest atteignant une MAE de 22,9 cycles. Les prochaines étapes consisteront à transformer le projet en un dashboard Streamlit déployable et à l'optimiser à l'aide du Gradient Boosting.